TECH CHALLENGE · FASE 2 · POS TECH FIAP

Ciência de Dados na Vitivinicultura

Prevendo a qualidade do vinho por meio de dados físico-químicos

FERNANDA ANDRETTO \ LUCAS WILLEMANN SIVIERO \ RAFAEL BERTHAULT \ RODRIGO DO NASCIMENTO SILVA

Made with GAMMA

Como realizar a classificação da qualidade de vinhos com precisão evitando subjetividades?

PROBLEMA · OPORTUNIDADE

A avaliação da qualidade do vinho depende de análises sensoriais feitas por especialistas, um processo demorado, subjetivo e que varia conforme a experiência dos avaliadores.

Podemos utilizar a ciência de dados e parâmetros físico-químicos (como acidez, teor alcoólico e enxofre) para apoiar enólogos a otimizar a produção e padronizar a excelência.

> Dataset utilizado: **Wine Quality Dataset - Kaggle** (contém informações físico-químicas de diferentes amostras de vinho, como acidez, teor alcoólico, densidade e níveis de dióxido de enxofre)

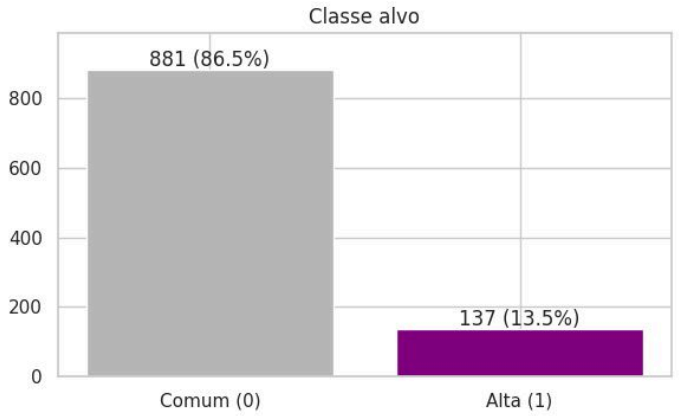
- **Simplificação Estratégica (Classificação Binária):**

  Vinho de Alta Qualidade (Nota >= 7)

  Vinho de Qualidade Comum (Nota < 7)

O **objetivo** é treinar modelos de Machine Learning para classificar lotes com alta precisão e identificar os fatores críticos de qualidade.

Made with GAMMA

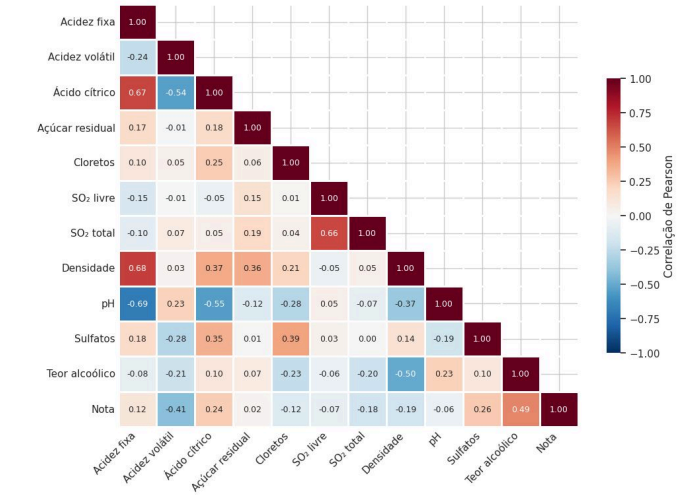


Identificamos um cenário de dados desbalanceados: cerca de **86,5% de vinhos de qualidade comum** contra **13,5% de alta qualidade**.

Como a classe de alta qualidade é minoritária, avaliamos precisão, recall e F1, além da acurácia.

Álcool e acidez volátil têm as maiores correlações com a nota

A matriz apresenta as associações entre todas as variáveis; correlação não implica causalidade.

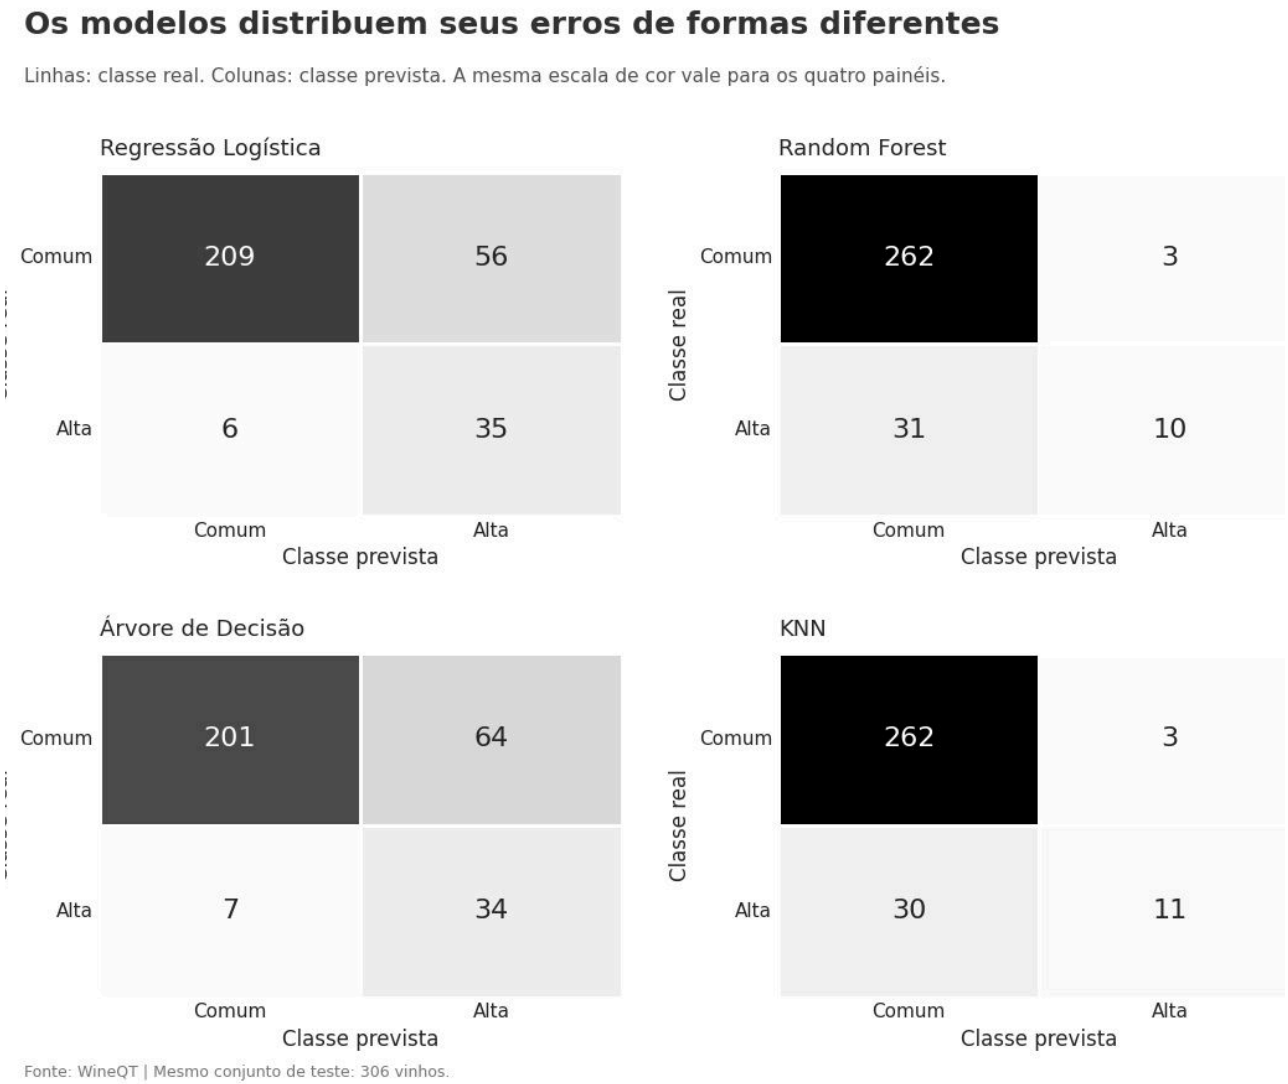


Fonte: WineQT | Correlações na base após remoção de duplicatas.

Principais associações com a nota:

- Maior teor alcoólico se associa a notas maiores.
- Maior acidez volátil se associa a notas menores.
- Essas associações não demonstram que alterar uma característica causará melhora na qualidade.

Made with GAMMA



MODELOS COMPARADOS

Regressão Logística vs. Random Forest vs. KNN vs. Árvore de Decisão

4 modelos com naturezas diferentes

- A Regressão Logística identificou corretamente 35 desses 41 vinhos. Porém, também classificou 56 vinhos comuns como de alta qualidade. Portanto, encontrou boa parte dos vinhos de interesse, mas produziu mais indicações incorretas.
- O Random Forest identificou corretamente 10 dos 41 vinhos de alta qualidade e classificou apenas 3 vinhos comuns como de alta qualidade. Suas indicações foram mais precisas, mas ele deixou de identificar 31 vinhos de alta qualidade.
- A Regressão Logística apresentou o maior F1 para a classe de alta qualidade neste teste, enquanto o Random Forest apresentou as maiores ROC-AUC e Average Precision. Essas métricas avaliam aspectos diferentes do desempenho, por isso não apontaram necessariamente para o mesmo modelo.

Made with GAMMA

LEITURA DOS SINAIS

Três variáveis concentram os principais influenciadores de qualidade

1

Teor alcoólico

Principal indicador associado à maturação e ao corpo.

2

Acidez volátil

Quando elevada, tende a degradar o sabor.

3

Sulfatos

Apresentaram associação positiva com a nota nesta base.

As características destacadas podem ajudar a equipe a acompanhar os lotes e investigar diferenças entre vinhos comuns e de alta qualidade.

Por exemplo, teor alcoólico, acidez volátil e sulfatos podem ser analisados em conjunto com a avaliação sensorial e com informações do processo produtivo.

Qualquer alteração no processo precisaria ser avaliada por profissionais da área e testada de forma controlada.

Made with GAMMA

Insights de Negócio e Implicações Práticas

- **Fatores Críticos de Qualidade:** O teor alcoólico e a acidez volátil se destacaram na diferenciação entre vinhos de qualidade comum e de alta qualidade nesta base. Esses resultados mostram associações, mas não permitem concluir como a maturação da uva ou a fermentação determinaram essas diferenças.
- Considerando o objetivo de encaminhar possíveis vinhos de alta qualidade à avaliação de especialistas, indicamos a **Regressão Logística** como modelo principal, pois identificou uma parcela maior dos vinhos de alta qualidade no teste. Caso a prioridade fosse reduzir indicações incorretas de vinhos comuns, o **Random Forest** mereceria maior atenção.
- **Apoio à Enologia:** O modelo preditivo desenvolvido serve como uma poderosa ferramenta de apoio aos enólogos, permitindo antecipar padrões de excelência durante o processo produtivo e auxiliando na padronização da qualidade do produto final. Contudo os resultados obtidos ainda não justificam seu uso para decidir automaticamente a classificação comercial de um vinho.



Made with GAMMA

Obrigado!

Ciência de Dados na Vitivinicultura

Modelos preditivos como apoio à avaliação de especialistas.

Fernanda Andretto

Lucas Willemann Siviero

Rafael Berthault

Rodrigo do Nascimento Silva

TECH CHALLENGE — FASE 2 · PÓS TECH FIAP

Made with GAMMA